LAFORTUNE EMERICK

|Computer Vision | NLP | ML/DL |

+33663732677 emerick.lafortune@gmail.com linkedin.com/in/emerick-lafortune https://lafortuneaiprojects.com/
Paris

EXPÉRIENCES

Computer vision & Full stack engineer (6 mois)

MBDA

2026

- Comparaison de méthodologies d'évaluation de la qualité d'images de synthèse par rapport au réel basées sur des métriques qualitatives de **traitement d'image** (PSD, SIFT, entropy,...), des métriques de scoring **deep learning** et des **modèles de fondation** (DA2, DINOV2, DSINE) pour réduire le domain gap
- Etudes approfondies de plusieurs méthodes de génération d'images : **Gaussian splatting** (3DGS), **Unreal Engine**, **transfer learning RGB → IR**
- Comparaison des méthodes de génération d'images en espace latent : détermination des métadonnées optimales de synthèse et des meilleures images des datasets générés
- **Développement Fullstack** (Python/TypeScript) : Conception d'une **app optimisée en production** (optimisation multi GPU et pour des datasets lourds de **+10 000 images**) pour l'analyse et le scoring permettant la validation visuelle et statistique des datasets de synthèse générés

Generative AI engineer & Computer Vision (6 mois)

Alten labs

2025

- **R&D IA générative et non générative en computer vision**
- Détection de piéton et tracking pour la sécurité routière des véhicules autonomes (détermination de l'intention de traversée)
- Implémentation d'approche générative basé sur le benchmark de modèle **VLM** suivi par un finetuning via **LoRA** (+11% recall)
- Approche non générative via un pipeline (segmentation, depth estimation, optical flow, keypoint tracking)
- **RAG multimodal** (texte + image) basé sur des vision transformers (Mask2Former, PixelFormer, Cotracker3)
- Optimisation GPU pour le passage des images dans le pipeline ViT (offloading, checkpointing, transfert numpy CPU-GPU, downcasting)
- Evaluation des modèles → 3 contextes : détection pure, détection des piétons en occlusion et détermination de l'intention piéton

Big data engineering (6 mois)

AirFrance KLM

2024

- **Automatisation de la création de bases de données miniatures** à partir de données de production pour les environnements de test
- **Extraction, transformation et gestion de données de production multi-services** (SQL, Shell)
- **Conception et orchestration de pipelines ETL** en PySpark, Hadoop, SQL et Shell pour le nettoyage et le traitement de données à grande échelle
- **Développement en production de pipelines robustes** pour la récupération et le traitement de centaines de tables provenant de services hétérogènes
- Ingestion, transformation, stockage de la donnée
- **Mise en place de pratiques DevOps** : automatisation des workflows, optimisation des temps de traitement, tests d'intégration et déploiement en CI/CD (Jenkins, GitHub)
- **Travail en environnement agile** (Jira, Confluence, Miro) avec collaboration étroite entre équipes data et IT

ÉDUCATION

Mathématiques et statistiques appliquées : Intelligence artificielle et machine learning

Institut polytechnique de Paris: Telecom sudParis

2021-2025

- **Statistiques → Machine Learning → data science** : apprentissage supervisé et non supervisé, statistiques paramétriques et non paramétriques, modèles graphiques
- **Big Data & Data Engineering** : pipelines ETL, SQL, PySpark, et shell
- **Développement Python avancé** : Programmation orientée objet (python) → deep learning, reinforcement learning, computer vision

Classe Préparatoire Maths Physique

Lycée Stanislas Cannes

09/2018 - 09/2021 Cannes

- Trois années de classes préparatoires **MPSI/MP** (Maths sup/Maths spé)

RÉSUMÉ

AI Engineer avec des expériences en **développement full stack & data engineering**, passionné par le ML, la computer vision et le NLP. Je réalise des projets end-to-end de la récupération des données à leur utilisation en IA via une interface full stack ou une implémentation en production permettant la résolution de problèmes concrets avec **rigueur, innovation et collaboration**.

RÉALISATIONS

Réalisation de modèles RAG

Benchmark d'architectures et de procédés d'optimisation de RAG (bi-encoders, retrieval hybride, re-ranking, quantification, augmentation du contexte, évaluation)

Computer vision tracking et détection

Benchmark de plusieurs méthodes de détection et tracking de traitement d'image classique (thresholding, kalman), de traitement d'image par IA (ViT, CNN) et d'optimisation des pipelines de traitement (pré-traitement, post traitement, quantification, latence)

deep learning/machine learning

Analyse d'architectures de réseau de neurones et d'algorithmes de ML, optimisation de l'entrainement, finetuning pour résoudre des problématiques concrètes

EXPÉRIENCES

Computer vision - Perception & Tracking

Emplacement

- **Fine-tuning** de YOLOv10 sur imagerie aérienne dense (VisDrone), export ONNX puis compilation TensorRT INT8 (calibration **PTQ**), inférence > 1000 FPS (×6 PyTorch, ×4,7 ONNXRuntime) pour 87% du mAP50-95 FP32 conservé
- Conception d'un moteur d'**inférence C++ GPU zero-copy** : pipeline NVDEC → prétraitement CUDA → TensorRT → tracking ByteTrack sans transfert CPU/GPU (Kalman), validation sur flux vidéo réel > 300 FPS
- **profiling quantification INT8** via Nsight Systems, containerisation Docker multi-stage (build/runtime)

GenAI / Computer Vision — Édition d'image assistée par IA générative

Emplacement

- **Orchestration multi-modèle** (VLM, segmentation, diffusion) : Conception d'un pipeline zero-shot object removal combinant Florence-2 (grounding textuel), reclassement CLIP, SAM2 et Stable Diffusion Inpainting, avec diagnostic et correction de 2 biais génératifs (négation de prompt, biais géométrique du masque)
- **Optimisation d'inférence GPU** : Accélération du UNet de diffusion via torch.compile/CUDA graphs (-88% de latence) et cache d'embeddings texte ; benchmark de quantification des poids (bitsandbytes/torchao) pour les couches linéaires et convolutives
- **Déploiement serverless & évaluation** : via FastAPI/WebSockets déployé sur HF Spaces (ZeroGPU), avec protocole d'évaluation (préservation, plausibilité, succès sémantique, dérive de quantification) adapté à l'inpainting génératif

NLP / LLM — RAG textuel données financières

Emplacement

- Mesure d'un RAG baseline sur un corpus de **documents financiers** (rapports annuels 10-K, texte et tableaux) : forte similarité de surface entre les passages (montants, tableaux répétées d'un document à l'autre) → difficulté de l'embedding générique à discriminer les passages réellement pertinents
- **Fine-tuning ciblé & recherche hybride** : Ré-entraînement contrastif du bi-encoder pour corriger ce défaut de discrimination, combiné à une recherche hybride lexicale (BM25) + sémantique (dense) fusionnée par reciprocal rank fusion
- **Re-ranking & génération ancrée** : Re-ranking par cross-encoder entraîné sur des négatifs difficiles extraits du pipeline, puis génération par LLM local quantifié (INT4)
- **Service en production** : Déploiement du pipeline complet (retrieval → rerank → génération) sur Hugging Face Spaces avec interface web et traçabilité complète (observabilité de chaque étape : latence, tokens, passages retenus)
- **Gain de performances** : recall 40% à 70% par finetuning du bi-encodeur puis 70% à 77% par recherche hybrique + re-ranking

Software Engineer (2 mois)

AV42

2022

- **Automatisation de processus métiers** en interne (prospection, gestion de projet)
- **Mise en place de pipelines d'ingestion de données automatisés**, depuis des API métiers jusqu'au stockage applicatif
- **Développement de workflows low-code/no-code** (n8n, Budibase) pour l'orchestration et la synchronisation de données inter-outils
- **Automatisation de processus métiers** (projet, comptabilité) réduisant les tâches manuelles et les risques d'erreur

Echange à l'étranger (Lituanie)

Vilnius University

2023

- **Programmation web** full stack en MERN (MongoDB, Express, React, Node) d'une interface utilisateur de commande de livres (HTML, CSS, back-end JavaScript)
- Windows API (C#) and financial technology classes (English)

CERTIFICATIONS

Toeic (score :965/990)

DeepLearning.ai: introduction to data engineering

LANGUES

Anglais
Langue maternelle

Espagnol
Avancé

Français
Langue maternelle

COMPÉTENCES

OpenCV · Pytorch · AWS · Production · Computer vision · Vite.js · TypeScript · Pyspark · Docker · Kubernetes · Deep Learning · Docker · GitHub · JavaScript · Jenkins · Jira · Bash · NLP · Numpy · Pandas · Pyspark · React · Scikit-Learn · Python · Pydantic · C++ · CUDA · MLOps · Model Monitoring · Testing & Validation

PASSIONS

- **Basket**
- **Échecs top 350 France (2270 elo)**
- **Développement de site webs**